Q-Learning

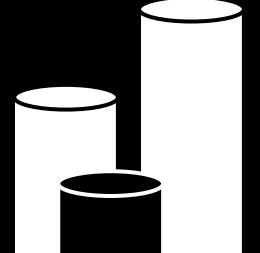
Como aprender quais ações tomar



Objetivo







Queremos estimar o valor **q** de cada ação, para poder escolher as melhores.

Para isto, precisamos explorar as ações do ambiente em cada estado para descobrir suas recompensas médias.

Dilema

Exploração

Explotação

Tomar novas ações para explorar estados diferentes

Pode levar a caminhos melhores

Menores recompensas a curto prazo



Aproveitar ações conhecidas

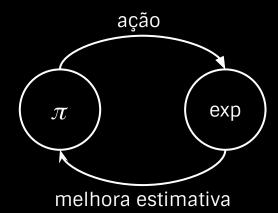
Maior recompensa com o conhecimento que já possui

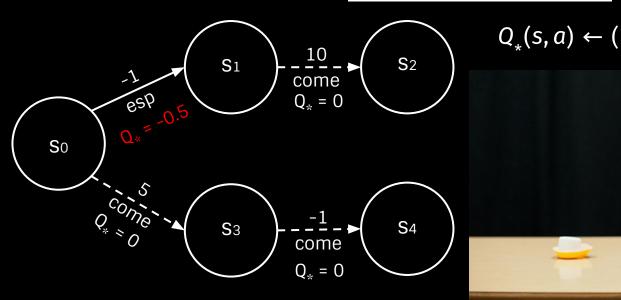
Não garante que se trata das melhores escolhas

Objetivo: buscar equilíbrio entre exploração e explotação

Q-Learning

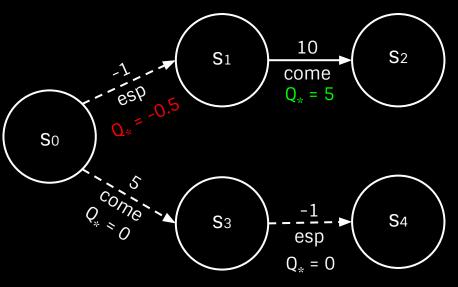
$$Q_*(s, a) \leftarrow (1 - \alpha) \cdot Q_*(s, a) + \alpha \cdot Q_*^{\text{novo}}(s, a)$$





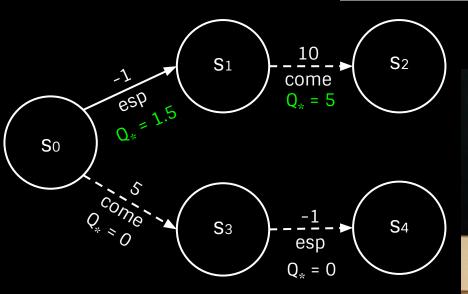
$$Q_*(s, a) \leftarrow (1 - \alpha) \cdot Q_*(s, a) + \alpha \cdot Q_*^{\text{novo}}(s, a)$$





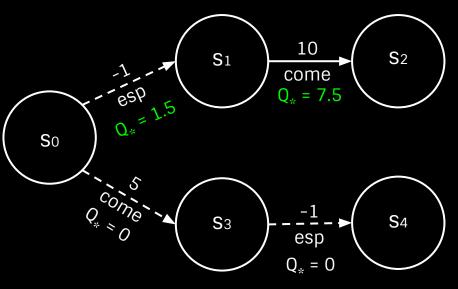
$$Q_{\star}(s,a) \leftarrow (1-\alpha) \cdot Q_{\star}(s,a) + \alpha \cdot Q_{\star}^{\text{novo}}(s,a)$$





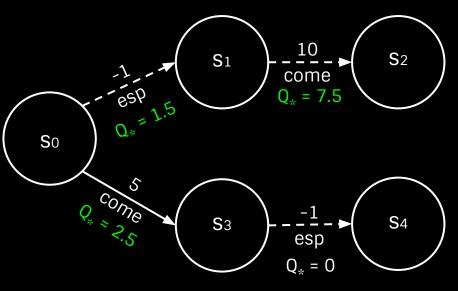
$$Q_{\star}(s,a) \leftarrow (1-\alpha) \cdot Q_{\star}(s,a) + \alpha \cdot Q_{\star}^{\mathsf{novo}}(s,a)$$





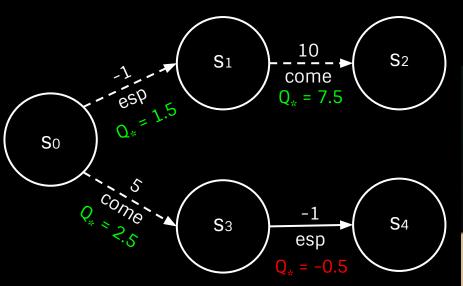
$$Q_{\star}(s,a) \leftarrow (1-\alpha) \cdot Q_{\star}(s,a) + \alpha \cdot Q_{\star}^{\mathsf{novo}}(s,a)$$





$$Q_{\star}(s, a) \leftarrow (1 - \alpha) \cdot Q_{\star}(s, a) + \alpha \cdot Q_{\star}^{\text{novo}}(s, a)$$





$$Q_{\star}(s,a) \leftarrow (1-\alpha) \cdot Q_{\star}(s,a) + \alpha \cdot Q_{\star}^{\mathsf{novo}}(s,a)$$



Como estimar os valores Q?

GRUPO TURING

Equação de Bellman

$$G_{t} = R_{t} + \gamma R_{t+1} + \gamma^{2} R_{t+2} + \cdots$$

$$v_{\pi}(s) = E_{\pi} \left[G_{t} \mid S_{t} = s \right]$$

$$q_*(s,a) = E_{\pi^*} [G_t \mid S_t = s, A_t = a]$$

$$= E_{\pi^*} \left[R_t + \gamma R_{t+1} + \gamma^2 R_{t+2} + \cdots \mid S_t = s, A_t = a \right]$$
 Retorno no instante t

$$= E_{\pi^*} \left[R_t + \gamma (R_{t+1} + \gamma R_{t+2} + \cdots) \mid S_t = S, A_t = a \right]$$
 Isolando o γ

$$= E_{\pi^*} \left[R_t + \gamma G_{t+1} \mid S_t = s, A_t = a \right]$$

$$= E_{\pi^*} [R_t + \gamma V_*(S_{t+1}) | S_t = s, A_t = a]$$

$$= E_{\pi^*} \left[R_t + \gamma \max_{a'} q_*(S_{t+1}, a') \middle| S_t = s, A_t = a \right]$$

Como o agente sempre toma a melhor ação

Bootstrapping



Como calcular essa média?

$$q_*(s, a) = E_{\pi^*} \left[R_t + \gamma \max_{a'} q_*(S_{t+1}, a') \mid S_t = s, A_t = a \right]$$

Uma estimativa bem grosseira: podemos considerar apenas um episódio

$$Q_{\text{bootstrap}}(s, a) = r + \gamma \cdot \max_{a'} Q_*(s', a')$$
recompensa fator de desconto valor futuro ótimo

Aplicação das conclusões: Q-learning



Q-Learning



Bootstrap gera estimativas ruins, que variam muito

$$Q_{\text{bootstrap}}(s, a) = r + \gamma \cdot \max_{a'} Q_{*}(s', a')$$
recompensa fator de desconto valor futuro ótimo

Podemos "estabilizar" esses valores usando uma média ponderada:

$$Q_*(s, a) \leftarrow (1 - \alpha) \cdot Q_*(s, a) + \alpha \cdot Q_{\text{bootstrap}}(s, a)$$

$$Q_{*}(s,a) \leftarrow (1-\alpha) \cdot \underbrace{Q_{*}(s,a)}_{\text{valor}} + \underbrace{\alpha \cdot \underbrace{\left(r + \gamma \max_{a'} Q_{*}(s',a')\right)}_{Q_{\text{bootstrap}}(s,a)}}_{\text{aprendizado}}$$



Q-Learning



$$Q_*(s, a) \leftarrow (1 - \alpha) \cdot Q_*(s, a) + \alpha \cdot Q_{\text{bootstrap}}(s, a)$$

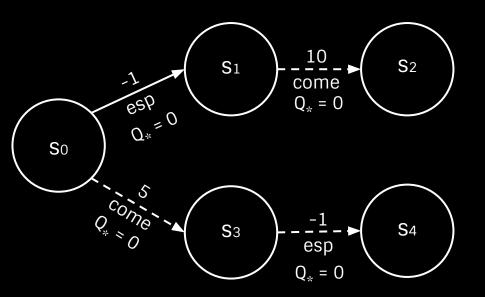
$$Q_{*}(s,a) \leftarrow (1-\alpha) \cdot \underbrace{Q_{*}(s,a)}_{\text{valor}} + \underbrace{\alpha \cdot \underbrace{\left(r + \gamma \max_{a'} Q_{*}(s',a')\right)}_{Q_{\text{bootstrap}}(s,a)}}_{Q_{\text{bootstrap}}(s,a)}$$

média ponderada

$$Q_{*}(s,a) \leftarrow Q_{*}(s,a) + \alpha \cdot \underbrace{\left(r + \gamma \max_{a'} Q_{*}(s',a') - Q_{*}(s,a)\right)}_{\text{valor antigo}} + \alpha \cdot \underbrace{\left(r + \gamma \max_{a'} Q_{*}(s',a') - Q_{*}(s,a)\right)}_{Q_{\text{bootstrap}}(s,a)}$$

minimização do erro

Exemplo (ep. 1)



$$\alpha = 0.5$$

 $y = 0.9$



$$\begin{split} Q_{\text{boot}}(s_0, \, \text{esp}) &= r + \gamma \max_{\alpha'} Q_{\star}(s_1, \alpha') = -1 + 0.9 \cdot 0 = -1 \\ Q_{\star}(s_0, \, \text{esp}) &\leftarrow (1 - \alpha) \cdot Q_{\star}(s_0, \, \text{esp}) + \alpha \cdot Q_{\text{boot}}(s_0, \, \text{esp}) \\ Q_{\star}(s_0, \, \text{esp}) &\leftarrow 0.5 \cdot 0 + 0.5 \cdot (-1) \\ Q_{\star}(s_0, \, \text{esp}) &\leftarrow -0.5 \end{split}$$

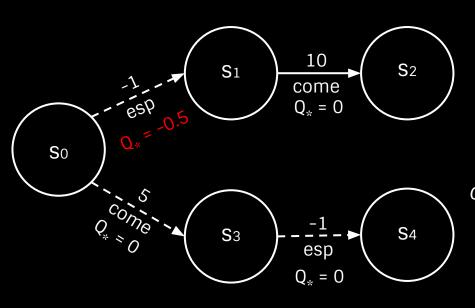


Exemplo (ep. 1)

$$\alpha = 0.5$$

 $v = 0.9$





$$\begin{aligned} Q_{\text{boot}}(s_0, \, \text{esp}) &= r + \gamma \max_{\alpha'} Q_*(s_1, \alpha') = -1 + 0.9 \cdot 0 = -1 \\ Q_*(s_0, \, \text{esp}) &\leftarrow (1 - \alpha) \cdot Q_*(s_0, \, \text{esp}) + \alpha \cdot Q_{\text{boot}}(s_0, \, \text{esp}) \\ Q_*(s_0, \, \text{esp}) &\leftarrow 0.5 \cdot 0 + 0.5 \cdot (-1) \\ Q_*(s_0, \, \text{esp}) &\leftarrow -0.5 \end{aligned}$$

$$Q_{\text{boot}}(s_1, \text{ come}) = r + \gamma \max_{a'} Q_*(s_2, a') = 10 + 0.9 \cdot 0 = 10$$

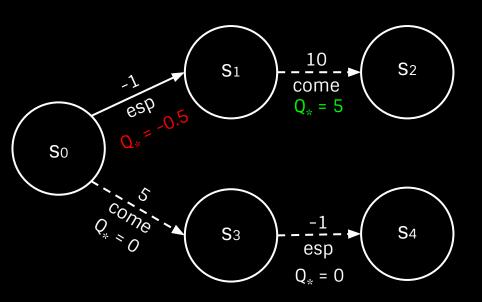
$$Q_*(s_1, \text{ come}) \leftarrow (1 - \alpha) \cdot Q_*(s_1, \text{ come}) + \alpha \cdot Q_{\text{boot}}(s_1, \text{ come})$$

$$Q_*(s_1, \text{ come}) \leftarrow 0.5 \cdot 0 + 0.5 \cdot 10$$

$$Q_*(s_1, \text{ come}) \leftarrow 5$$



Exemplo (ep. 2)



$$\alpha = 0.5$$

 $y = 0.9$



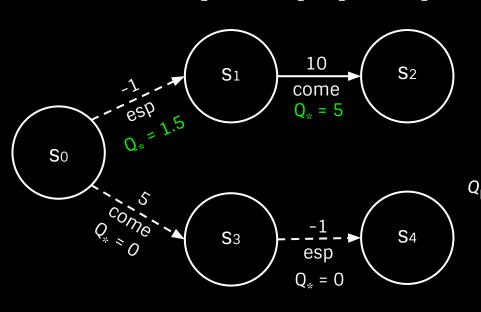
$$\begin{split} Q_{\text{boot}}(s_0, \, \text{esp}) &= r + \gamma \max_{a'} Q_*(s_1, a') = -1 + 0.9 \cdot 5 = 3.5 \\ Q_*(s_0, \, \text{esp}) &\leftarrow (1 - \alpha) \cdot Q_*(s_0, \text{esp}) + \alpha \cdot Q_{\text{boot}}(s_0, \, \text{esp}) \\ Q_*(s_0, \, \text{esp}) &\leftarrow 0.5 \cdot (-0.5) + 0.5 \cdot 3.5 \\ Q_*(s_0, \, \text{esp}) &\leftarrow 1.5 \end{split}$$



Exemplo (ep. 2)







$$\begin{split} Q_{\text{boot}}(s_0, \, \text{esp}) &= r + \gamma \max_{\alpha'} Q_*(s_1, \alpha') = -1 + 0.9 \cdot 5 = 3.5 \\ Q_*(s_0, \, \text{esp}) &\leftarrow (1 - \alpha) \cdot Q_*(s_0, \text{esp}) + \alpha \cdot Q_{\text{boot}}(s_0, \, \text{esp}) \\ Q_*(s_0, \, \text{esp}) &\leftarrow 0.5 \cdot (-0.5) + 0.5 \cdot 3.5 \\ Q_*(s_0, \, \text{esp}) &\leftarrow 1.5 \end{split}$$

$$Q_{\text{boot}}(s_1, \text{ come}) = r + \gamma \max_{a'} Q_*(s_2, a') = 10 + 0.9 \cdot 0 = 10$$

$$Q_*(s_1, \text{ come}) \leftarrow (1 - \alpha) \cdot Q_*(s_1, \text{ come}) + \alpha \cdot Q_{\text{boot}}(s_1, \text{ come})$$

$$Q_*(s_1, \text{ come}) \leftarrow 0.5 \cdot 5 + 0.5 \cdot 10$$

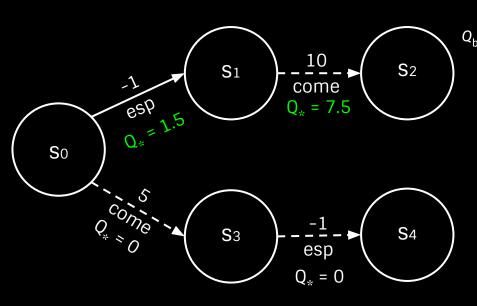
$$Q_*(s_1, \text{ come}) \leftarrow 7.5$$



Exemplo (ep. 3)







$$\begin{split} Q_{\text{bootstrap}}(s_0, \, \text{espera}) &= r + \gamma \max_{\alpha'} Q_{\star}(s_1, \alpha') = -1 + 0.9 \cdot 7.5 = 5.75 \\ Q_{\star}(s_0, \, \text{espera}) &\leftarrow (1 - \alpha) \cdot Q_{\star}(s_0, \, \text{espera}) + \alpha \cdot Q_{\text{bootstrap}}(s_0, \, \text{espera}) \\ Q_{\star}(s_0, \, \text{espera}) &\leftarrow 0.5 \cdot 1.5 + 0.5 \cdot 5.75 \\ Q_{\star}(s_0, \, \text{espera}) &\leftarrow 3.625 \end{split}$$

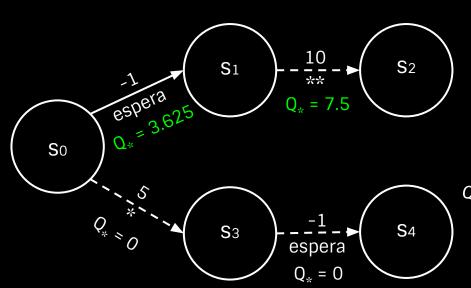


Exemplo (ep. 3)

$$\alpha = 0.5$$

 $\gamma = 0.9$





$$\begin{aligned} Q_{\text{boot}}(s_0, \, \text{esp}) &= r + \gamma \max_{\alpha'} Q_*(s_1, \alpha') = -1 + 0.9 \cdot 7.5 = 5.75 \\ Q_*(s_0, \, \text{esp}) &\leftarrow (1 - \alpha) \cdot Q_*(s_0, \, \text{esp}) + \alpha \cdot Q_{\text{bootstrap}}(s_0, \, \text{esp}) \\ Q_*(s_0, \, \text{esp}) &\leftarrow 0.5 \cdot 1.5 + 0.5 \cdot 5.75 \\ Q_*(s_0, \, \text{esp}) &\leftarrow 3.625 \end{aligned}$$

$$Q_{\text{boot}}(s_1, \text{ come}) = r + \gamma \max_{\alpha'} Q_{\star}(s_2, \alpha') = 10 + 0.9 \cdot 0 = 10$$

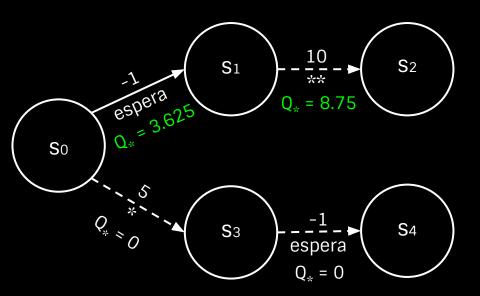
$$Q_{\star}(s_1, \text{ come}) \leftarrow (1 - \alpha) \cdot Q_{\star}(s_1, \text{ come}) + \alpha \cdot Q_{\text{boot}}(s_1, \text{ come})$$

$$Q_{\star}(s_1, \text{ come}) \leftarrow 0.5 \cdot 7.5 + 0.5 \cdot 10$$

$$Q_{\star}(s_1, \text{ come}) \leftarrow 8.75$$



Exemplo (ep. 3)



 $\alpha = 0.5$ $\gamma = 0.9$





Q-Learning Tabular

Q-learning funciona armazenando as estimativas dos Q-valores numa tabela.

As estimativas da tabela são atualizadas através da já mencionada equação de Bellman.

Q	а0	a1	a2
s0	1	15	2
s1	24	5	16
s2	10	62	-7
s3	10	15	35



Algoritmo de Q-Learning

```
Parâmetros: parâmetros \alpha, \gamma \in (0, 1], \varepsilon pequeno > 0.

Inicialize Q(s, a), arbitrariamente, para todo s, a, exceto quando Q(terminal, \cdot) = 0

Loop para cada episódio:

Inicialize S

Loop para cada instante do episódio:

Escolha A usando uma política derivada de Q (e.g, \varepsilon-gulosa)

Tome a ação A, observe R, S'

Q(S, A) \leftarrow Q(S, A) + \alpha \left[R + \gamma \max_{a'} Q(S', a') - Q(S, A)\right]
S \leftarrow S'

até que S seja o estado terminal
```



Recursos



Turing Talks: textos desde o básico de RL até algoritmos mais avançados

Curso:

 Reinforcement Learning (Coursera)

Livro:

 Reinforcement Learning: An Introduction (Sutton, Barto)

