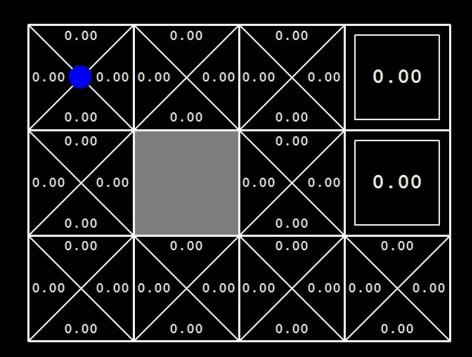
Q-Learning

Como aprender quais ações tomar



Objetivo



Queremos estimar o valor **q** de cada ação, para poder escolher as melhores.

Para isto, precisamos explorar as ações do ambiente em cada estado para descobrir suas recompensas médias.

CURRENT Q-VALUES



Explotação

Exploração

Aproveitar ações conhecidas

Maior recompensa com o conhecimento que já possui

Não garante que se trata das melhores escolhas

Tomar novas ações para explorar estados diferentes

Pode levar a caminhos melhores

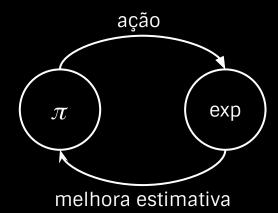
Menores recompensas a curto prazo

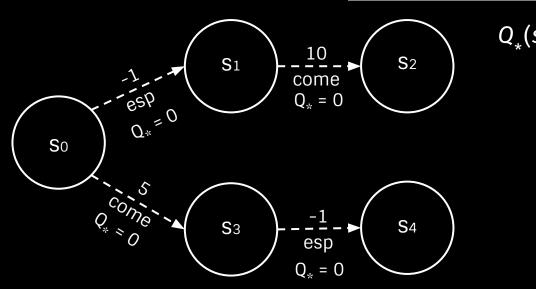


Objetivo: buscar equilíbrio entre exploração e explotação

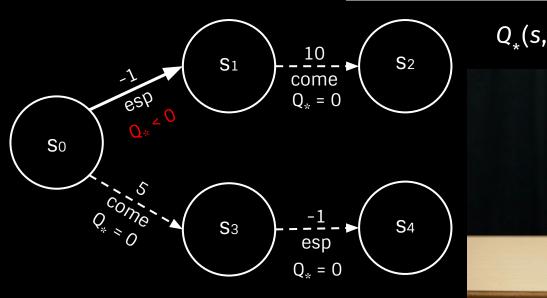
Q-Learning

$$Q_*(s, a) \leftarrow (1 - \alpha) \cdot Q_*(s, a) + \alpha \cdot Q_*^{\text{novo}}(s, a)$$



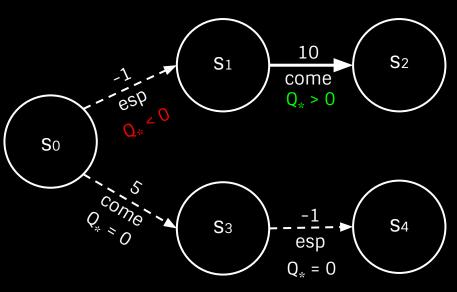


$$Q_{\star}(s, a) \leftarrow (1 - \alpha) \cdot Q_{\star}(s, a) + \alpha \cdot Q_{\star}^{\text{novo}}(s, a)$$



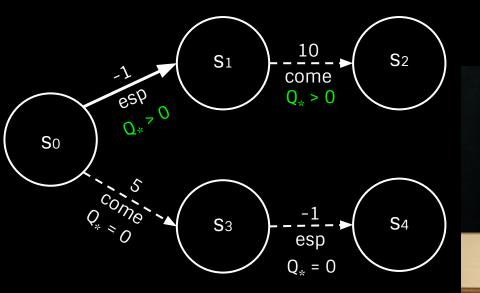
$$Q_*(s, a) \leftarrow (1 - \alpha) \cdot Q_*(s, a) + \alpha \cdot Q_*^{\text{novo}}(s, a)$$





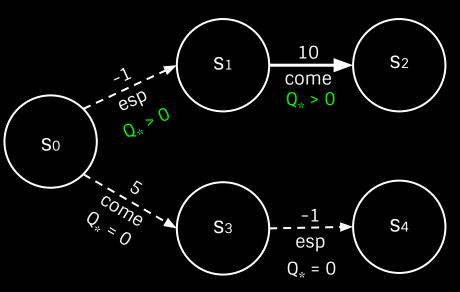
$$Q_*(s, a) \leftarrow (1 - \alpha) \cdot Q_*(s, a) + \alpha \cdot Q_*^{\text{novo}}(s, a)$$





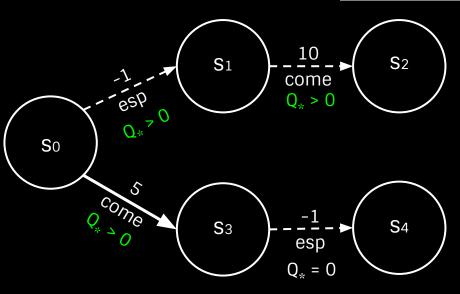
$$Q_*(s, a) \leftarrow (1 - \alpha) \cdot Q_*(s, a) + \alpha \cdot Q_*^{\text{novo}}(s, a)$$





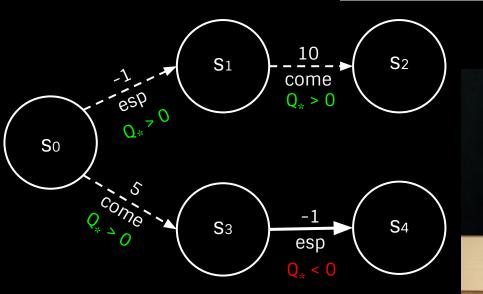
$$Q_{\star}(s, a) \leftarrow (1 - \alpha) \cdot Q_{\star}(s, a) + \alpha \cdot Q_{\star}^{\text{novo}}(s, a)$$





$$Q_{\star}(s,a) \leftarrow (1-\alpha) \cdot Q_{\star}(s,a) + \alpha \cdot Q_{\star}^{\text{novo}}(s,a)$$





$$Q_*(s, a) \leftarrow (1 - \alpha) \cdot Q_*(s, a) + \alpha \cdot Q_*^{\text{novo}}(s, a)$$



Como estimar os valores Q?

GRUPO TURING

Equação de Bellman

$$G_t = R_t + \gamma R_{t+1} + \gamma^2 R_{t+2} + \cdots$$

$$V_{\pi}(s) = E_{\pi} \left[G_t \mid S_t = s \right]$$

$$q_*(s,a) = E_{\pi^*} \left[G_t \mid S_t = s, A_t = a \right]$$

$$= E_{\pi^*} \left[R_t + \gamma R_{t+1} + \gamma^2 R_{t+2} + \cdots \mid S_t = s, A_t = a \right]$$
 Retorno no instante t

$$= E_{\pi^*} \left[R_t + \gamma (R_{t+1} + \gamma R_{t+2} + \cdots) \mid S_t = s, A_t = a \right]$$
 Isolando o γ

$$= E_{\pi^*} \left[R_t + \gamma G_{t+1} \mid S_t = s, A_t = a \right]$$

$$= E_{\pi^*} [R_t + \gamma V_*(S_{t+1}) | S_t = S, A_t = a]$$

$$= E_{\pi^*} \left[R_t + \gamma \max_{a'} q_*(S_{t+1}, a') \middle| S_t = s, A_t = a \right]$$

Como o agente sempre toma a melhor ação

Bootstrapping



Como calcular essa média?

$$q_*(s, a) = E_{\pi^*} \left[R_t + \gamma \max_{a'} q_*(S_{t+1}, a') \mid S_t = s, A_t = a \right]$$

Uma estimativa bem grosseira: podemos considerar apenas um episódio

$$Q_{\text{bootstrap}}(s, a) = r + \gamma \cdot \max_{a'} Q_*(s', a')$$
recompensa fator de desconto valor futuro ótimo

Aplicação das conclusões: Q-learning



Q-Learning



Bootstrap gera estimativas ruins,
que variam muito
$$Q_{\text{bootstrap}}(s,a) = r + \gamma \cdot \max_{a'} Q_*(s',a')$$
recompensa fator de desconto valor futuro ótimo

Podemos "estabilizar" esses valores usando uma média ponderada:

$$Q_*(s, a) \leftarrow (1 - \alpha) \cdot Q_*(s, a) + \alpha \cdot Q_{\text{bootstrap}}(s, a)$$

$$Q_{*}(s,a) \leftarrow (1-\alpha) \cdot \underbrace{Q_{*}(s,a)}_{\text{valor}} + \underbrace{\alpha \cdot \underbrace{\left(r + \gamma \max_{a'} Q_{*}(s',a')\right)}_{Q_{\text{bootstrap}}(s,a)}}_{\text{aprendizado}}$$



Q-Learning



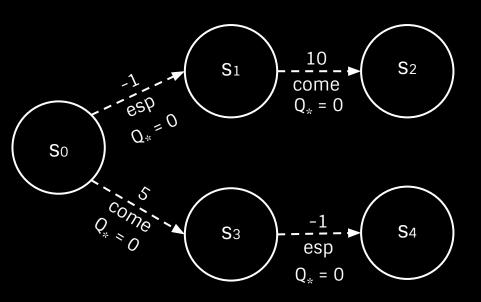
$$Q_*(s, a) \leftarrow (1 - \alpha) \cdot Q_*(s, a) + \alpha \cdot Q_{\text{bootstrap}}(s, a)$$

$$Q_{*}(s,a) \leftarrow (1-\alpha) \cdot \underbrace{Q_{*}(s,a)}_{\text{valor}} + \underbrace{\alpha \cdot \underbrace{\left(r + \gamma \max_{a'} Q_{*}(s',a')\right)}_{Q_{\text{bootstrap}}(s,a)}}_{Q_{\text{bootstrap}}(s,a)}$$

média ponderada

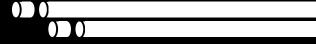
$$Q_{*}(s,a) \leftarrow Q_{*}(s,a) + \alpha \cdot \underbrace{\left(r + \gamma \max_{a'} Q_{*}(s',a') - Q_{*}(s,a)\right)}_{\text{valor antigo}} + \alpha \cdot \underbrace{\left(r + \gamma \max_{a'} Q_{*}(s',a') - Q_{*}(s,a)\right)}_{Q_{\text{bootstrap}}(s,a)}$$

minimização do erro



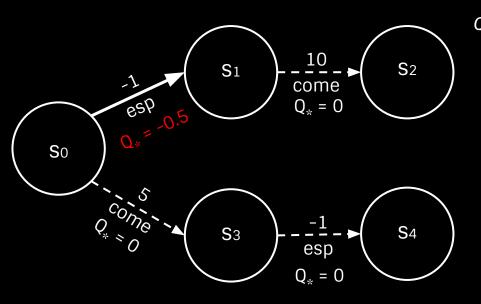
 $\alpha = 0.5$

$$\gamma = 0.9$$





Exemplo (ep. 1)



$$\alpha = 0.5$$

 $y = 0.9$



$$\begin{split} Q_{\text{boot}}(s_0, \, \text{esp}) &= r + \gamma \max_{\alpha'} Q_{\star}(s_1, \alpha') = -1 + 0.9 \cdot 0 = -1 \\ Q_{\star}(s_0, \, \text{esp}) &\leftarrow (1 - \alpha) \cdot Q_{\star}(s_0, \text{esp}) + \alpha \cdot Q_{\text{boot}}(s_0, \, \text{esp}) \\ Q_{\star}(s_0, \, \text{esp}) &\leftarrow 0.5 \cdot 0 + 0.5 \cdot (-1) \\ Q_{\star}(s_0, \, \text{esp}) &\leftarrow -0.5 \end{split}$$

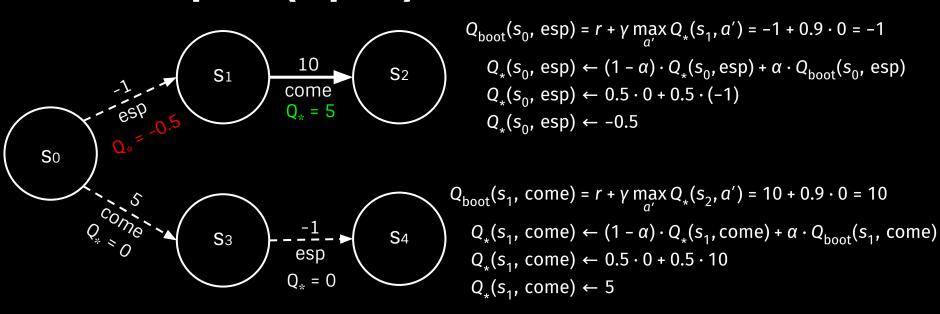


Exemplo (ep. 1)

$$\alpha = 0.5$$

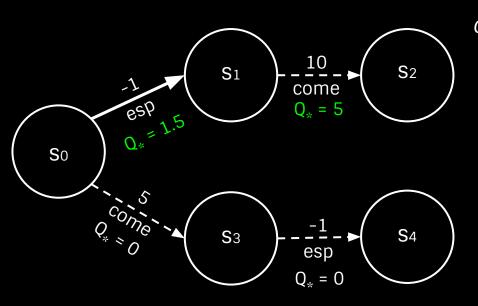
 $y = 0.9$







Exemplo (ep. 2)



$$\alpha = 0.5$$
 $\gamma = 0.9$



$$\begin{aligned} Q_{\text{boot}}(s_0, \, \text{esp}) &= r + \gamma \max_{\alpha'} Q_{\star}(s_1, \alpha') = -1 + 0.9 \cdot 5 = 3.5 \\ Q_{\star}(s_0, \, \text{esp}) &\leftarrow (1 - \alpha) \cdot Q_{\star}(s_0, \, \text{esp}) + \alpha \cdot Q_{\text{boot}}(s_0, \, \text{esp}) \\ Q_{\star}(s_0, \, \text{esp}) &\leftarrow 0.5 \cdot (-0.5) + 0.5 \cdot 3.5 \\ Q_{\star}(s_0, \, \text{esp}) &\leftarrow 1.5 \end{aligned}$$



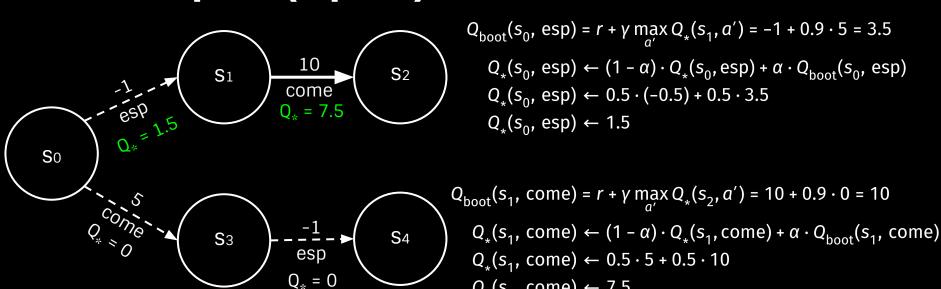
Exemplo (ep. 2)

$$\alpha = 0.5$$

 $v = 0.9$

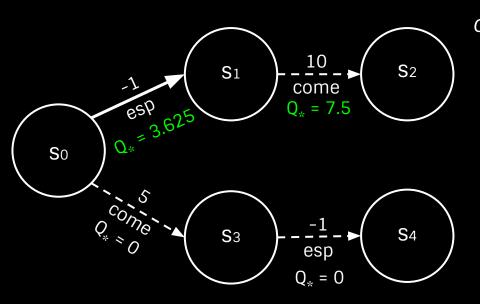
 $Q_{\star}(s_1, come) \leftarrow 7.5$







Exemplo (ep. 3)



$$\alpha = 0.5$$
 $y = 0.9$



$$\begin{aligned} Q_{\text{boot}}(s_0, \, \text{esp}) &= r + \gamma \max_{\alpha'} Q_*(s_1, \alpha') = -1 + 0.9 \cdot 7.5 = 5.75 \\ Q_*(s_0, \, \text{esp}) &\leftarrow (1 - \alpha) \cdot Q_*(s_0, \, \text{esp}) + \alpha \cdot Q_{\text{boot}}(s_0, \, \text{esp}) \\ Q_*(s_0, \, \text{esp}) &\leftarrow 0.5 \cdot 1.5 + 0.5 \cdot 5.75 \\ Q_*(s_0, \, \text{esp}) &\leftarrow 3.625 \end{aligned}$$

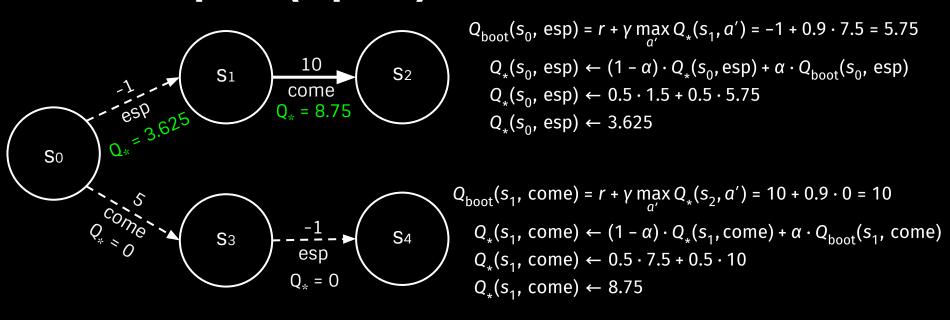


Exemplo (ep. 3)

$$\alpha = 0.5$$

 $y = 0.9$







Q-Learning Tabular

Q-learning funciona armazenando as estimativas dos Q-valores numa tabela.

As estimativas da tabela são atualizadas através da já mencionada equação de Bellman.

Q	а0	a1	a2
s0	1	15	2
s1	24	5	16
s2	10	62	-7
s3	10	15	35



Algoritmo de Q-Learning

```
Parâmetros: parâmetros \alpha, \gamma \in (0, 1], \varepsilon pequeno > 0.

Inicialize Q(s, a), arbitrariamente, para todo s, a, exceto quando Q(terminal, \cdot) = 0

Loop para cada episódio:
    Inicialize S
    Loop para cada instante do episódio:
        Escolha A usando uma política derivada de Q (e.g, \varepsilon-gulosa)
        Tome a ação A, observe R, S'

Q(S, A) \leftarrow Q(S, A) + \alpha \left[R + \gamma \max_{a} Q(S', a') - Q(S, A)\right]
S \leftarrow S'

até que S seja o estado terminal
```



Recursos



<u>Turing Talks</u>: textos desde o básico de RL até algoritmos mais avançados

Repositório de RL do Grupo Turing: explicações e implementações de diversos algoritmos

Curso:

 Reinforcement Learning (Coursera)

Livro:

 Reinforcement Learning: An Introduction, 2a ed. (Sutton, Barto)

